




Análisis exploratorio: Estimación de la Edad Ósea (EO)

Jennifer Sandoval 18962

Esteban del Valle 18221

Luis Quezada 18028

Situación problemática



Desventajas del método tradicional

- Mayor tiempo de estimación
- Error causado por el factor humano
- Necesidad de un profesional
- Falta de precisión


(BMJ, 2000).

Problema Científico

¿Cuál es la importancia de la estimación de la edad ósea?

- Identificación de enfermedades que afectan el desarrollo
- Control de desarrollo óseo
- Monitoreo de crecimiento

Fig. 3. Depiction of the order of appearance of the individual carpal bones. The usual sequence is: capitate (1), hamate (2), triquetral (3), lunate (4), trapezium (5), trapezoid (6), navicular or scaphoid (7) and pisiform (8). The distal epiphysis of the radius ossifies before the triquetrum and that of the ulna before the pisiform



(Lepe, et. al, 2018).

Objetivos

- EDA
 - Datos e imágenes
- Estudiar datos categóricos y cuantitativos
- Reconocimiento de patrones
- Características generales
- Identificación de variables significativas


Descripción de los Datos

Variable	Clasificación	Tipo de dato
id	Categórica	int
boneage	Continua	int
sex	Categórica	int

Análisis Exploratorio


	id	sex	boneage
count	12611.000000	12611.000000	12611.000000
mean	8537.653001	0.541829	127.320752
std	4108.763993	0.498267	41.182021
min	1377.000000	0.000000	1.000000
25%	5074.500000	0.000000	96.000000
50%	8565.000000	1.000000	132.000000
75%	12091.500000	1.000000	156.000000
max	15610.000000	1.000000	228.000000

Estadística descriptiva




Distribución de edades óseas

Análisis Exploratorio




Distribución de edades óseas por sexo



Frecuencia de datos por sexo
(0 mujeres, 1 hombres)

Análisis Exploratorio



EDA de Imágenes

```
*-----*
number of images          | 12611

dtype                     | uint8
channels                  | [1]
extensions                | ['png']


min height                | 640
max height                | 2989
mean height               | 1664.247878835937
median height             | 1624

min width                 | 521
max width                 | 3001
mean width                | 1319.3485052731742
median width              | 1277


mean height/width ratio   | 1.2614164280205484
median height/width ratio | 1.2717306186374315
recommended input size(by mean) | [1664 1320] (h x w, multiples of 8)
recommended input size(by mean) | [1664 1312] (h x w, multiples of 16)
recommended input size(by mean) | [1664 1312] (h x w, multiples of 32)

channel mean(0~1)         | 0.18266279810284672
channel std(0~1)          | 0.1951994388377542
*-----*
eda ended in 00 hours 07 minutes 25 seconds
```

EDA de Imágenes




Distribución de tamaños de imágenes



Canales de píxeles identificados


Modelo 1

- Neuronas de entrada 128x128x1
- Convolutional Layer (32)
- Convolutional Layer (64)
- Max Pooling
- Dropout y flatten
- Dense de 200 neuronas
- Dense de 200 neuronas
- Dropout final
- Dense (1 neurona final)




Modelo 2

- Neuronas de entrada 128x128x1
- Convolutional Layer (32)
- Convolutional Layer (64)
- Max Pooling
- Dropout y flatten
- Dense de 200 neuronas
- Dense de 400 neuronas
- Dense de 50 neuronas
- Dense de 100 neuronas
- Dropout final
- Dense (1 neurona final)




Modelo 3

- Neuronas de entrada 128x128x1
- Convolutional Layer (32)
- Convolutional Layer (64)
- Max Pooling
- Dropout y flatten
- Dense de 500 neuronas
- Dense de 100 neuronas
- Dense de 100 neuronas
- Dense de 50 neuronas
- Dense de 100 neuronas
- Dropout final
- Dense (1 neurona final)




Modelo 4

- Neuronas de entrada 128x128x1
- Convolutional Layer (32)
- Convolutional Layer (64)
- Max Pooling
- Dropout y flatten
- Dense de 512 neuronas con regularizador L2
- Dense de 1024 neuronas con regularizador L2
- Dense de 512 neuronas con regularizador L2
- Dropout final
- Dense (1 neurona final)




Modelo 5

- Neuronas de entrada 128x128x1
- Convolutional Layer (32)
- Convolutional Layer (64)
- Max Pooling
- Dropout y flatten
- Dense de 200 neuronas
- Dense de 400 neuronas
- Dense de 200 neuronas
- Dense de 100 neuronas
- Dropout final
- Dense (1 neurona final)




Modelo 6

- Neuronas de entrada 128x128x1
- Convolutional Layer (16)
- Dropout (0.3)
- Convolutional Layer (32)
- Dropout (0.25)
- Convolutional Layer (32)
- Convolutional Layer (64)
- Convolutional Layer (128)
- Dropout (0.3)
- Flatten
- Dense de 300 neuronas
- Dense de 100 neuronas
- Dense (1 neurona final)




Modelo 7


- Neuronas de entrada 128x128x1
- Convolutional Layer (16)
- Dropout (0.3)
- Convolutional Layer (32)
- Dropout (0.3)
- Convolutional Layer (32)
- Convolutional Layer (64)
- Convolutional Layer (128)
- Dropout (0.3)
- Flatten
- Dense de 200 neuronas
- Dense de 100 neuronas
- Dense de 10 neuronas
- Dense (1 neurona final)




Modelos de Predicción




Predicciones con el Modelo Óptimo



Predicciones con el Modelo Óptimo



Predicciones con el Modelo Óptimo




Ejemplos de Predicción



Real: 15
Pred: 15.7



Real: 11.5
Pred: 11.9




Real: 12.5
Pred: 12.7

Hallazgos y Conclusiones

- Más Hombres
- Fin de formación de la mano en pubertad
- Mayoría de datos alrededor de 13 años

- Tamaño de la imagen ajustable
- 1 canal: blanco y negro
- Cuadro identificador podría causar ruido

- Desarrollo de modelo de redes neuronales convolucionales
- Modelo 6



Modelo con menor MSE

Referencias

Bay, Tuytelaars y Gool. (2019). SURF: Speeded Up Robust Features. ETH Zurich. Extraído de: <https://people.ee.ethz.ch/~surf/>

Chin, M. (2016). UCLA researchers release open source code for a powerful image detection algorithm. UCLA Newsroom. Extraído de: <https://newsroom.ucla.edu/releases/ucla-researchers-release-open-source-code-for-powerful-image-detection-algorithm>

Elhakeem. (2019). Teens who hit puberty later could face bone health issues later in life, studies suggest. Extraído de: <https://theconversation.com/teens-who-hit-puberty-later-could-face-bone-health-issues-later-in-life-studies-suggest-121470>

Gavrilova y Stryungis. (2020). **Machine Learning Algorithm Classification for Beginners**. Serokell. Extraído de: <https://serokell.io/blog/machine-learning-algorithm-classification-overview>

Hospital de San Diego. (2011). Radiografía: edad ósea. Extraído de: <https://www.rchsd.org/health-articles/radiografa-estudio-de-la-edad-sea/>

Pose Lepe, Georgette, Villacrés, Fabián, Silva Fuente-Alba, Claudio, & Guiloff, Stefan. (2018). Correlación en la determinación de la edad ósea radiológica mediante el método de Greulich y Pyle versus la evaluación automatizada utilizando el software BoneXpert. *Revista chilena de pediatría*, 89(5), 606-611. <https://dx.doi.org/10.4067/S0370-41062018005000705>

S. Yang, P. Luo, C. C. Loy, and X. Tang, "From Facial Parts Responses to Face Detection: A Deep Learning Approach", in IEEE International Conference on Computer Vision (ICCV), 2015.

Silva y Freire. (2019). Introducción a las redes neuronales convolucionales. Medium. Extraído de: <https://medium.com/@bootcampai/redes-neuronales-convolucionales-5e0ce960caf8>

Yadav, S.S., Jadhav, S.M. (2019). Deep convolutional neural network based medical image classification for disease diagnosis. *J Big Data* 6, 113. <https://doi.org/10.1186/s40537-019-0276->